

Vision document

1) Контекст и проблема

Компании в РФ/СНГ хотят использовать LLM в продуктах и процессах, но сталкиваются с типовыми проблемами:

- доступ к зарубежным API нестабилен (VPN, блокировки, платежи)
- сложно контролировать расходы и лимиты по командам/проектам
- нет прозрачности: кто, куда и сколько тратит
- риски отказов провайдеров
- нужен контроль доступа (роли) для корпоративной эксплуатации

2) Целевые пользователи

- SaaS-продукты и интеграторы, которые встраивают AI в свой сервис
- Компании с несколькими командами, которым нужно контролировать роли и доступы, лимиты по проектам
- Стартапы и команды разработки, желающие сравнить и протестировать разные модели

3) Ценность

Мы даём компаниям единую точку доступа к разным LLM через единый API, чтобы:

- подключение происходило быстрее
- расходы были управляемыми и прогнозируемыми
- доступ был в рублях и без VPN
- продукт клиента не падал при сбоях конкретного провайдера

4) Предложение продукта

- Единый API (OpenAI-compatible) - один endpoint и один ключ для доступа к каталогу моделей.
- Оплата в рублях / доступ без VPN - удобная закупка и эксплуатация в российских условиях.
- Каталог моделей - выбор моделей под качество/цену/скорость.
- Гибкие лимиты - лимиты по токенам/периодам, по проекту.
- Аналитика - кто/что/сколько использовал: по проектам, ролям, ключам, моделям.
- Роли - разные уровни доступа: админ компании, менеджер проекта, разработчик, наблюдатель/финансы.
- Отказоустойчивость - fallback: при недоступности

провайдера/модели переключаем на запасной вариант по правилам;
ретраи, таймауты, контроль деградации качества/стоимости.

CJM

User requirements

1) Владелец компании

Цель: подключить организацию и управлять доступом.

Требования:

- создать организацию (компанию) и настроить базовые параметры
- подключить оплату в рублях и видеть баланс/счета
- создать проекты
- управлять пользователями организации (приглашать, удалять, блокировать)
- назначать роли пользователям (RBAC)
- создавать/отзывать API-ключи
- настраивать лимиты/бюджеты на организацию и проекты
- настраивать политики поведения при превышении лимита: остановка или переход на дешевую модель
- задавать правила fallback (если модель/провайдер недоступен)
- включать/настраивать логирование и его уровень (что сохраняем)
- просматривать аудит действий (кто что менял)
- видеть статусы провайдеров/моделей

2) Project Manager (владелец проекта внутри компании)

Цель: управлять конкретным проектом и его потреблением.

Требования:

- создавать и настраивать проект (описание, теги)
- создавать ключи проекта
- задавать лимиты проекта (по токенам/запросам/периоду)
- ограничивать список доступных моделей для проекта
- задавать правила fallback (если модель/провайдер недоступен)
- просматривать аналитику по проекту: usage/cost, топ ключей/пользователей/эндпоинтов
- настраивать алерты по проекту
- выгружать отчёты по проекту

3) Developer (интегрирует API в продукт)

Цель: быстро подключиться и стабильно отправлять запросы.

Требования:

- получить ключ и endpoint

- использовать единый OpenAI-compatible API
- выбрать модель из каталога (и понимать её цену/ограничения)
- отправлять запросы и получать предсказуемые ошибки с понятными сообщениями
- видеть технические логи запросов (по своему ключу)
- понимать, на какую модель ушёл запрос (например при fallback)

4) Finance Viewer

Цель: контролировать расходы и распределение затрат.

Требования:

- видеть расходы по периодам (день/неделя/месяц)
- видеть детализацию: проект, модель, ключ/пользователь
- выгружать отчёты для бухгалтерии/внутреннего контроля
- режим “только просмотр” без права менять настройки

USM